

AI 伺服馬達故障風險預測與預測性維護建議系統：

基於 UCI AI4I 2020 的端到端預測性維護原型

Chen Yu Hsu

Abstract—本專題建立一套面向工業設備與伺服馬達應用情境的預測性維護原型系統。系統使用 UCI AI4I 2020 Predictive Maintenance Dataset 作為公開合成資料來源，依 CRISP-DM 流程完成商業理解、資料理解、資料準備、建模、評估與部署。實作內容包含資料探索分析、避免資料洩漏的前處理流程、特徵工程、十種模型與五種特徵組合的比較、Optuna 超參數調整、SHAP 單筆解釋、第二階段故障類型分析、What-if 敏感度分析、互動式決策門檻，以及 FastAPI 與 Streamlit 雙介面展示。最佳模型為 Gradient Boosting 搭配 D_rfe_top8 特徵組合，在測試集上達到 $F1=0.887$ 、 $Recall=0.809$ 、 $ROC-AUC=0.969$ 、 $PR-AUC=0.906$ 。本系統定位為預測性維護原型與維護決策輔助工具，不直接控制馬達，也不宣稱已完成真實場域之精準剩餘壽命預測。

Index Terms—預測性維護、故障風險預測、機器學習、CRISP-DM、FastAPI、Streamlit、SHAP、UCI AI4I 2020

I. Introduction

工業設備與伺服馬達長時間運轉時，常受到溫度、轉速、扭矩、負載與磨耗等因素影響。一旦設備在未預警狀態下故障，可能導致產線停機、維修成本增加、交期延誤與品質風險。因此，透過資料分析與機器學習建立故障風險預測模型，是工業 AI 與智慧製造領域中具有實務價值的應用方向。

本專題以「AI 伺服馬達故障風險預測與預測性維護建議系統」為題，目標不是直接控制馬達，而是提供設備健康狀態評估、故障機率預測、維護建議與決策輔助。由於真實伺服馬達長期運轉到故障的資料不易取得，本專題採用 UCI AI4I 2020 Predictive Maintenance Dataset 作為原型開發資料。此資料集為合成資料，適合建立預測性維護流程、模型比較與展示系統，但不應被解讀為真實工廠驗證結果。

本報告採類 IEEE 雙欄格式撰寫，內容依 CRISP-DM 流程描述問題定義、資料與特徵、模型設計、實驗結果、系統架構與限制。主要貢獻如下：

- 建立從資料下載、EDA、前處理、建模、評估到部署的端到端專案架構。
- 比較 10 個模型與 5 個特徵組合，並以 $F1$ 、 $Recall$ 、 $ROC-AUC$ 、 $PR-AUC$ 作為主要評估依據。
- 將模型成果落地為 FastAPI 與 Streamlit 雙介面，支援單筆預測、批次預測、模型解釋、門檻調整與 What-if 分析。
- 在 README、模型卡與報告中明確標示資料限制，避免誇大為真實伺服馬達壽命預測。

Repository: <https://github.com/ChenYuHsu413/AIFinalProject>. 本報告依據 AI 職訓專題實作紀錄整理。

II. Project Positioning and Business Understanding

本專題的商業問題可定義為：在工業設備持續運轉的情境下，如何利用可取得的感測與運轉資料，提前辨識設備故障風險並提供維護建議，以降低突發停機與維修成本。目標使用者包含設備維護人員、產線工程師、AI 職訓專題展示對象，以及未來可能接入真實設備資料的工業應用開發者。

系統定位如 Fig. 1 所示。輸入資料包含產品類型、環境溫度、製程溫度、轉速、扭矩與磨耗時間。系統輸出包含故障機率、預測類別、健康分數、風險等級、可能故障類型與維護建議。健康分數使用簡化規則計算：

$$HealthScore = (1 - P_{failure}) \times 100. \quad (1)$$

其中 $P_{failure}$ 為模型輸出的故障機率。風險等級則依機率門檻分為低、中、高三類，並可透過互動式門檻頁面調整。

III. Data Understanding

本專題使用 UCI AI4I 2020 Predictive Maintenance Dataset。資料共有 10000 筆，故障比例約 3.39%，無缺失值。由於故障樣本遠少於正常樣本，若只使用 Accuracy 可能造成誤判：模型即使大多預測為正常，也可能得到很高的準確率。因此本專題在評估時採用 $F1$ 、 $Recall$ 、 $ROC-AUC$ 與 $PR-AUC$ 等更適合不平衡分類問題的指標。

資料理解階段完成下列分析：資料筆數與欄位型態、缺失值檢查、故障樣本比例、故障類型分布、數值欄位描述統計、Type 類別分布、特徵與故障標籤的初步關係，以及相關係數熱圖。EDA 共產出 target 分布、Type 分布、failure types、numeric 分布與 correlation heatmap 等圖表。

IV. Data Preparation and Feature Engineering

資料準備階段的核心原則是避免資料洩漏。由於 TWF、HDF、PWF、OSF、RNF 是故障類型標籤，若將其放入特徵矩陣 X 來預測 Machine failure，模型會直接讀到結果資訊，造成不合理高分。因此第一階段模型僅使用設備運轉相關欄位與衍生特徵。

前處理流程採用 sklearn Pipeline 與 ColumnTransformer。類別欄位 Type 使用 One-Hot Encoding；數值欄位依模型需求進行標準化；資料切分使用 stratify 維持訓練集與測試集中的故障比例一致。Scaler 與 encoder 只在訓練資料中 fit，再 transform 到測試資料，以避免資料洩漏。

除原始特徵外，本專題新增五個具工業意義的衍生特徵，如 Table II 所示。這些特徵用於描述溫度差、負載代理、磨耗與扭矩或轉速之交互作用，使模型能捕捉多因素共同造成的風險。

TABLE I: AI4I 2020 主要欄位與建模用途

欄位	類型	用途與說明
UDI	ID	流水號，移除，不作為模型特徵。
Product ID	ID	產品編號，移除，避免模型記憶編號。
Type	類別	產品等級或類型，使用 One-Hot Encoding。
Air temperature [K]	數值	環境溫度。
Process temperature [K]	數值	製程或設備運轉溫度。
Rotational speed [rpm]	數值	旋轉速度，可對應馬達轉速。
Torque [Nm]	數值	扭矩，可對應負載程度。
Tool wear [min]	數值	工具磨耗，可類比累積運轉或零件磨耗。
Machine failure	Target	第一階段二元分類目標。
TWF/HDF/PWF/OSF/RNF	Target	故障類型標籤，不放入 X 預測 Machine failure。

TABLE II: 衍生特徵與工業意義

衍生特徵	工業意義
temp_diff	製程溫度減環境溫度，反映設備運轉額外熱負荷。
power_proxy	扭矩乘轉速，作為功率負載的近似指標。
wear_torque_interaction	磨耗與高扭矩同時發生時的風險。
wear_speed_interaction	磨耗與高速運轉交互作用。
temp_wear_interaction	高溫與磨耗交互作用，反映潛在退化風險。

V. Modeling Method

本專題共比較十種模型與五種特徵組合。模型包含 Logistic Regression、Decision Tree、Random Forest、SVM、Gradient Boosting、XGBoost、LightGBM、KNN、MLPClassifier 與 Naive Bayes。其中 Logistic Regression 作為基準模型；Random Forest 與 Gradient Boosting 代表常見樹系集成模型；SVM、KNN 與 MLP 用於比較標準化後的非線性分類能力。

特徵組合包含原始特徵、原始加衍生特徵、SelectKBest、RFE 與 Random Forest importance 等方法。實驗設計可表示為：

$$N_{train} = N_{model} \times N_{feature_set} = 10 \times 5 = 50. \quad (2)$$

此外，針對 model comparison 的前 3 名模型進行 Optuna 超參數調整，共 45 個 trials，並使用 3-fold cross validation 評估搜尋結果。

VI. Evaluation and Results

在預測性維護情境中，漏掉真正故障樣本的成本通常高於誤報。因此本專題不以 Accuracy 作為唯一選模指標，而是將 F1、Recall、ROC-AUC 與 PR-AUC 作為主要參考。Precision 高但 Recall 低的模型可能漏掉故障；Recall 高但 Precision 低的模型可能造成較多誤報。最終模型需在維護決策情境中取得平衡。

TABLE III: 模型與特徵實驗規模

項目	數量或內容
模型數量	10 個模型
特徵組合	5 種特徵組合
主要訓練次數	50 次模型訓練
Optuna 調參	45 個 trials
單元測試	9 / 9 passed
圖表產出	22 張 PNG
應用服務	FastAPI 8 個端點、Streamlit 5 個頁面

TABLE IV: 最佳模型測試集結果

指標	數值
Best model	Gradient Boosting / D_rfe_top8
F1	0.887
Recall	0.809
ROC-AUC	0.969
PR-AUC	0.906
TN	1931
FP	1
FN	13
TP	55

最佳模型為 Gradient Boosting / D_rfe_top8，其測試集結果如 Table IV 所示。此模型在 F1、Recall 與 PR-AUC 之間取得良好平衡，因此被選為 demo 版本主要模型。

互動式決策門檻分析顯示，預設門檻 0.50 不一定是最佳值。當門檻調整為 0.30 時，F1 可提升至 0.892，優於預設門檻下的 0.887。此結果可作為教學展示：分類模型的輸出機率需要根據實際決策成本調整，而非固定使用 0.50。

第二階段故障類型分析針對 TWF、HDF、PWF、OSF、RNF 各自訓練模型。結果顯示 PWF 接近完美辨識，主要原因是資料生成規則使其與扭矩及轉速高度相關；HDF 與 OSF 表現良好；TWF 在預設門檻下 F1 較差，但 ROC 顯示仍有排序訊號；RNF 則因資料本質接近隨機而幾乎不可預測。此結果提醒：模型上限受到資料生成機制與訊號強弱限制，並非所有標籤都能透過演算法解決。

Optuna 調參結果也被誠實納入模型卡。45 個 trials 後，最佳調參模型在測試集 F1 未超越原始 Gradient Boosting，因此系統自動保留原始最佳模型。這項結果強調：超參數調整不保證一定提升測試表現，held-out test 仍是必要驗證。

VII. System Implementation

系統實作分為資料科學模組、模型服務層與展示介面三部分。資料科學模組位於 src/，包含資料載入、前處理、特徵工程、特徵選擇、訓練、評估、預測、模型解釋與視覺化。應用層包含 FastAPI backend 與 Streamlit dashboard。

FastAPI 提供 8 個端點：/health、/model_info、/predict、/predict_full、/batch_predict、/metrics、/failure_type_metrics 與 /docs。其中 /predict_full 回傳故障機率、健康分數、風險等級、維護建議與第二階段故障類型機率。

Streamlit 提供 5 個頁面：手動單筆預測、What-if 敏感度分析、批次 CSV 上傳、模型評估結果與關於本專案。手動預測頁整合 SHAP Top 10 bar chart，協助使用者理解哪些特徵推高或降低故障風險。What-if 頁面提供 1D 掃

描曲線與 2D 風險地景熱圖，可用來示範轉速、扭矩、溫度與磨耗變化對模型輸出的影響。

VIII. Software Engineering and DevOps

本專案不只包含模型訓練，也包含工程化與部署準備。`config.yaml` 集中管理路徑、模型、特徵組合、風險門檻與維護建議門檻；`requirements.txt` 管理相依套件；`tests/` 包含 9 個單元測試，涵蓋資料洩漏防護、衍生特徵、標準化、維護建議規則與輸出 schema。

DevOps 方面，專案包含 Dockerfile、docker-compose.yml、.dockerignore 與 GitHub Actions CI。Docker 以 `python:3.11-slim` 為基底，並安裝 `libgomp1` 以支援 LightGBM / XGBoost 等套件。docker-compose 以同一 image 啟動 API 與 UI 服務，並 bind mount `data/` 與 `outputs/`。CI workflow 使用 Python 3.11 / 3.12 matrix，執行 `py_compile`、`pytest` 與 Docker buildx smoke test。

IX. Discussion

本專題有數個教學與實務上的亮點。第一，完整展示了 CRISP-DM 如何從商業問題一路延伸到部署介面。第二，透過互動式門檻調整，說明分類模型的最佳決策門檻不必然等於 0.50。第三，透過 RNF 與 PWF 的對比，說明資料訊號強弱與資料生成規則會限制模型表現。第四，透過模型卡自動產生與 Optuna 調參失敗仍保留原模型的設計，呈現誠實且可追溯的 ML 工作流程。

本專題也刻意將規則式維護建議與機率式模型並用。故障機率來自資料驅動模型；維護建議則由可解釋規則產生，例如高溫差建議檢查散熱、高扭矩建議檢查負載、高磨耗建議安排保養。這種做法在 demo 階段有助於提高可解釋性，也讓使用者能理解系統輸出不是黑箱結論。

X. Limitations and Future Work

本專題最大的限制是 AI4I 2020 為合成資料，不能直接外推到真實伺服馬達或工廠產線。其次，資料並非時間序列，缺乏同一設備從健康到故障的完整歷程，因此無法進行嚴謹的 Remaining Useful Life (RUL) 預測。再次，部分故障類型如 RNF 由資料設計上接近隨機，模型難以預測；TWF 在預設門檻下也仍有限制。

未來若能取得實際伺服馬達資料，可接入電流、電壓、震動、溫度、轉速、扭矩、警報碼與維修紀錄，並改用 survival analysis、time-series classification 或 RUL regression 方法。部署方面可進一步在 GCP VM 上建置 FastAPI backend、前端靜態網站、Nginx reverse proxy 與 systemd service；MLOps 方向則可加入定期重訓、特徵漂移監控、模型版本管理與預測審計。

XI. Conclusion

本專題完成一套 demo 級成熟的 AI 預測性維護原型系統。從資料處理、特徵工程、模型比較、調參、解釋、評估到 FastAPI / Streamlit 展示，皆具備完整流程。最佳模型 Gradient Boosting / `D_rfe_top8` 在測試集取得 $F1=0.887$ 、 $Recall=0.809$ 、 $ROC-AUC=0.969$ 與 $PR-AUC=0.906$ 。雖然本專題使用合成資料，尚不能宣稱為真實伺服馬達壽命預測系統，但其架構、工程流程與評估方法可作為未來接入真實工業資料的基礎。

Appendix A Repository Summary

專案已推送到 GitHub：<https://github.com/ChenYuHsu413/AIFinalProject>。最終包含 53 個檔案、約 3500 行程式碼、22 張圖表、雙語 README、Docker、GitHub Actions CI 與 MIT License。主要指令包含 `train`、`evaluate`、`train_failure_types`、`tune`、`predict`、`run_eda`、`streamlit run`、`uvicorn` 與 `docker compose up`。

Appendix B Project Structure

專案架構包含 `src/data`、`src/features`、`src/models`、`src/visualization`、`app/streamlit_app.py`、`app/backend`、`tests`、`outputs`、`data`、`notebooks` 與 `scripts`。此結構將資料處理、模型訓練、應用服務與測試分離，避免所有功能集中在單一檔案中。

References

- [1] S. Matzka, "AI4I 2020 Predictive Maintenance Dataset," UCI Machine Learning Repository, 2020. [Online]. Available: <https://archive.ics.uci.edu/dataset/601/ai4i+2020+predictive+maintenance+dataset>
- [2] R. Wirth and J. Hipp, "CRISP-DM: Towards a standard process model for data mining," in *Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery and Data Mining*, 2000.
- [3] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [4] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems*, 2017.
- [5] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proc. ACM SIGKDD*, 2019.



Fig. 1: 專題資訊圖表。圖中摘要呈現專案定位、CRISP-DM 流程、資料與特徵、模型規模、最佳模型結果、系統功能、教學亮點與未來方向。